

重慶理工大學

《深度学习》课程论文

题　目　基于 Transformer 的中文短文本摘要生成方法研究与实现

学　院　计算机科学与工程学院

专　业

班　级

姓　名

学　号

时　间　　年　　月

基于 **Transformer** 的中文短文本摘要生成方法研究与实现

摘要：针对中文资讯阅读成本较高的问题，本文研究基于预训练 BART 的中文短文本摘要生成方法。采用 LCSTS 数据整理版本，在不同训练数据规模下微调模型，并与原文截取和 TextRank 方法进行比较。使用字符级 ROUGE 及生成案例评价摘要质量。在 725 条自划分测试样本上，10K 模型采用束搜索时的 ROUGE-1、ROUGE-2 和 ROUGE-L 分别为 0.3480、0.2229 和 0.3140，均高于截取、TextRank 和 2K 模型。案例显示模型能够提取事件信息，生成结果中也存在数字对应关系错误。

关键词：中文文本摘要；Transformer；BART；预训练模型；ROUGE

1 引言

互联网平台持续产生大量中文资讯。读者常通过标题和简短介绍判断是否阅读全文；当信息量增长时，人工筛选与整理摘要的成本也随之上升。自动摘要旨在从文本中提炼主要内容并形成较短表达，可用于资讯聚合、检索结果和内容预览。

摘要方法通常分为抽取式和生成式。抽取式方法从原文选取句子或片段，结果容易追溯，但受原文位置及表达方式约束。直接截取开头计算成本低，却可能只保留背景而遗漏后文的关键数量或结论。生成式方法能够压缩和重组信息，但可能产生与原文不一致的实体、数字和因果关系，因此需要同时评价文本重合和事实正确性。

Transformer 利用注意力机制建立序列内部及输入输出之间的关联 [1]。BART 在编码器—解码器结构上通过重建受扰动文本进行预训练，适合迁移到摘要任务 [2]。本文以中文短资讯为场景，使用 LCSTS 数据整理版本，在预训练中文 BART 上进行全参数微调，并比较截取基线、不同训练规模和解码方式。本文结合生成结果分析模型的信息压缩能力及事实错误，讨论实验边界和后续改进方向。

资讯摘要不仅需要保留事件主体和动作，还需要交代数量、时间等限定信息。标题式参考摘要经常将多个事实压缩到一个短句中，因此摘要系统必须同时处理内容选择与语言组织。本文将原文前 30 字作为低成本的位置基线，将句子排序方法作为抽取式对照，再与生成模型比较，以观察不同信息选择方式对摘要质量的影响。

2 数据与方法

2.1 数据来源与划分

LCSTS 是面向中文短文本摘要的数据集 [3]。本文使用整理版本 `aligeniewcp22/LCSTS`，数据版本与获取方式见项目 README。该版本提供训练数据、有标签验证数据和公开测试数据；其说明指出，有标签验证数据保留人工评分为 3 至 5 的样本 [4]。

数据预处理包括检查原文及参考摘要非空、去除两端空白，以及将每条记录转换为统一格式。先用随机种子 42 打乱有标签验证数据，再按原文去重，从中选取 1 000 条验证样本和 725 条自划分测试样本。训练集抽样前排除与这两部分原文完全相同的记录，从原训练集采用蓄水池抽样得到 10 000 条，再从中抽取 2 000 条。两组训练集共用验证集与自划分测试集，2K 训练集是 10K 的子集。验证集用于选择模型，自划分测试集用于方法比较。

由于所用整理版本的公开测试文件没有参考摘要，本文从有标签验证数据中划分自

划分测试集，用于各方法的统一比较。实验记录表明训练、验证和测试集之间的原文精确交集均为零。

两组模型使用一致的数据划分，以便比较训练规模。训练样本的原文如果与验证或测试样本完全一致，会使模型可能直接记住文本，因此抽样前先排除完全相同的原文。后续评价可进一步检查不同集合中对同一事件的改写。

2.2 模型结构

给定原文序列 $X = (x_1, \ldots, x_n)$ 和摘要序列 $Y = (y_1, \ldots, y_m)$，摘要生成可表示为条件序列生成问题：

$$P(Y \mid X) = \prod_{t=1}^{m} P(y_t \mid y_{<t}, X). \tag{1}$$

本文使用公开的 `OpenMOSS-Team/bart-base-chinese` 预训练模型 [5]，其编码器和解码器各有 6 层，隐藏层维度为 768，每层注意力有 12 个头。原文经分词并映射为向量后，编码器通过双向自注意力和前馈网络形成上下文表示；解码器根据已生成词元，通过交叉注意力读取编码器输出，逐步预测下一个词元。

注意力根据查询 Q 和键 K 的相似程度对值 V 加权。缩放点积注意力为：

$$\mathrm{Attention}(Q, K, V) = \mathrm{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V, \tag{2}$$

其中 d_k 为键向量维度 [1]。编码器自注意力建立原文词元之间的联系；解码器自注意力受因果掩码约束，只使用当前位置之前的词元；交叉注意力使生成过程利用原文表示。本文沿用预训练结构及权重，训练时以参考摘要监督词元预测，更新全部可训练参数，填充位置不参与损失计算，未增加额外网络支路。

模型所用分词器为 BertTokenizer：它先进行基本分词，再使用 WordPiece 词表拆分词元，中文字符会先单独切分，连续拉丁词串可拆分为子词。模型配置的解码器起始词元 ID 为 102（复用词表中的 [SEP] 词元作为起始符）；解码时以该词元作为初始输入，随后由已生成词元构成 $y_{<t}$。输入词元嵌入与可学习的位置嵌入相加，为注意力层提供顺序信息。编码器输出同时供解码器交叉注意力使用：查询来自解码器当前隐藏状态，键和值来自原文表示，由此在每一步为生成选择相关上下文。训练采用目标序列右移的教师强制方式，推理阶段则使用模型自身生成的历史。

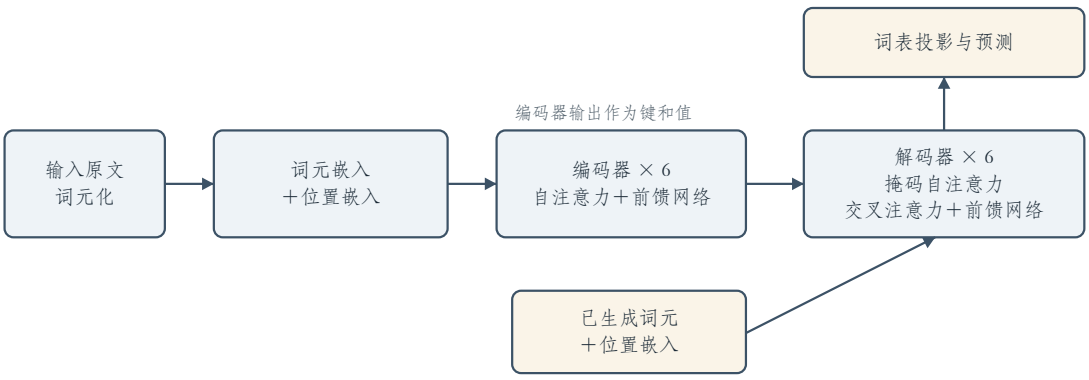


图 1: BART 编码器—解码器结构及摘要生成流程

图 1 中的结构是对预训练模型的任务化使用。编码器和解码器各包含六层，多头注意力在不同表示子空间计算权重，前馈网络对每个位置的表示作非线性变换。解码器的掩码防止训练时读取未来词元；交叉注意力则连接原文与输出，使生成的标题既利用历史摘要，也能从输入中选取事件信息。

2.3 训练、解码与评价

采用模型对应的分词器，原文和目标摘要长度上限分别为 128 和 32 token，超长部分截断，批内动态填充。两组模型均使用 AdamW，初始学习率 3×10^{-5}，线性衰减、不预热，批大小为 4，训练 3 轮，随机种子为 42。每轮结束计算验证损失，选取损失最低的模型生成摘要。实验在 NVIDIA GeForce RTX 4070 SUPER 上进行，采用 PyTorch 2.6、CUDA 12.4 和 Transformers 4.57。

对照包括原文前 30 字截取、TextRank 抽取，以及 2K 和 10K 模型分别使用贪心搜索与束搜索。贪心搜索每步只保留当前概率最高的词元；束搜索每步保留多个候选序列，本文束宽为 4。两种策略均关闭随机采样，最多生成 32 个新 token，输出时去除特殊词元和分词引入的空白。

TextRank 将句子作为图节点，根据内容相似度建立带权边并迭代更新节点得分 [6]。本实验按句号、问号、感叹号、分号及换行切分句子；以单个汉字及连续英文或数字串作为词元，英文统一小写。两句边权为词元多重集合重合数除以两句词元数分别加一后取对数之和。排序阻尼系数为 0.85，最多迭代 100 次，最大变化小于 10^{-8} 时停止；无出边节点均匀分配权重。选得分最高的句子，同分取原文中较早者，再截取前 30 字。该实现采用明确的排序与截断规则，输出既包括完整句子，也包括截断片段。

本文使用去除空白后的字符级 ROUGE F1[7]。ROUGE-N 统计候选和参考中的字符 N 元片段及其多重集合交集；分别以交集大小 c、候选片段数 n_p 和参考片段数 n_r 计算精确率与召回率。ROUGE-L 则以最长公共子序列长度作为 c，以候选和参考的字符数作为分母。两类指标均按下式计算，并先逐样本计算再取算术平均：

$$P = \frac{c}{n_p}, \quad R = \frac{c}{n_r}, \quad F_1 = \frac{2PR}{P + R}. \tag{3}$$

当候选或参考为空、无重合，或 $P + R = 0$ 时，按实现将该样本的 F1 记为零。ROUGE 衡量与参考文本的表面重合，事实关联还需结合输入原文检查。

3 实验与结果

3.1 验证损失与模型选择

图 2 给出训练和验证损失。训练曲线为每 50 次参数更新所记录的区间平均损失，横轴按训练轮次表示；验证曲线为每轮结束时的验证集平均损失。两组模型使用同一验证集，最终选择验证损失最低的检查点。

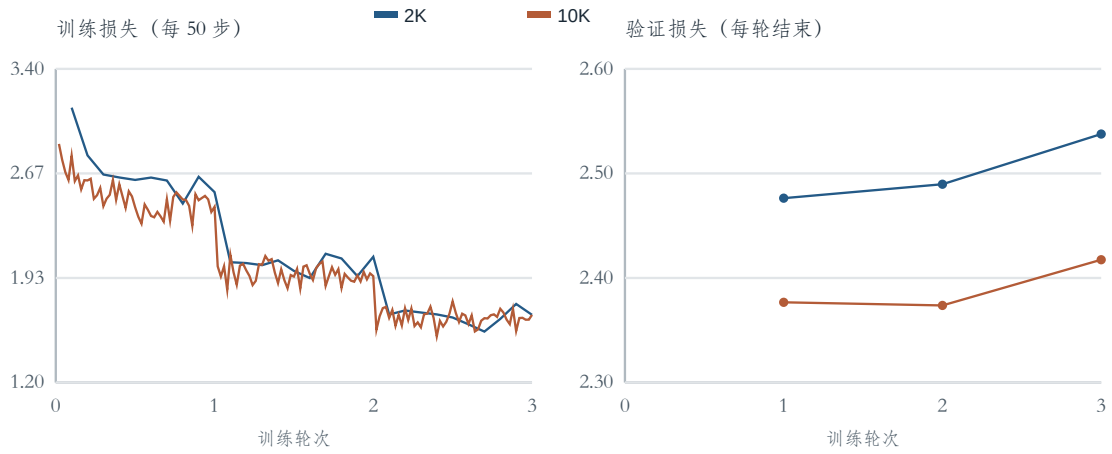


图 2: 训练与验证损失曲线

表 1: 各轮验证损失与选中轮次

训练样本数	第 1 轮	第 2 轮	第 3 轮	选中轮次
2 000	2.4763	2.4897	2.5377	1
10 000	2.3767	2.3737	2.4174	2

2K 模型的验证损失在第 1 轮最低，随后连续上升；10K 模型在第 2 轮达到最低，第 3 轮回升。模型在各轮重复遍历训练样本，训练损失在轮次交界附近呈阶梯式下降，而验证损失在后期回升，呈现出过拟合迹象。10K 组的最低验证损失低于 2K 组，最佳轮次也有所延后，表现出较好的验证集适应能力。验证损失反映词元级预测能力，摘要生成质量还通过测试集上的 ROUGE 指标评价。

3.2 摘要生成性能与解码策略比较

表 2 汇总 725 条自划分测试样本的结果。长度为每条输出的平均字符数；耗时为逐条生成的总时间，不含模型加载与指标计算。BART 在 GPU 上推理，两个抽取基线在 CPU 上运行，表中耗时反映本次实验的逐条生成开销。

表 2: 不同方法在自划分测试集上的结果

方法	R-1	R-2	R-L	平均长度	耗时/s
前 30 字	0.2495	0.1427	0.2138	30.00	0.0002
TextRank	0.2437	0.1375	0.2090	28.53	0.0642
BART 2K，贪心	0.3174	0.1958	0.2889	16.92	60.13
BART 2K，束搜索	0.3213	0.2028	0.2923	16.42	75.05
BART 10K，贪心	0.3479	0.2197	0.3125	16.37	54.44
BART 10K，束搜索	0.3480	0.2229	0.3140	15.84	68.88

四组 BART 结果均高于两个抽取基线。10K 束搜索相对于前 30 字截取，ROUGE-1、ROUGE-2 和 ROUGE-L 分别提高 0.0985、0.0802 和 0.1002；其平均输出长度为 15.84 字，约为截取长度的一半。参考摘要采用标题式表达，生成模型可以重组输入信息，因此在较短输出下仍取得更高的字符重合度。

相同束搜索设置下，10K 相比 2K 的三项指标分别提高 0.0267、0.0201 和 0.0217。贪心设置下 10K 也全面高于 2K，说明本次实验中数据规模的作用在两种解码方式下均可观察到。在 2K 组，束搜索相对贪心的 ROUGE-2 提高 0.0070；10K 组提高 0.0032。束搜索对指标的提升小于扩大训练数据带来的提升，同时两组的生成耗时分别增加约 14.92 秒和 14.44 秒。相同解码策略下，10K 模型的生成耗时比 2K 略短，平均输出分别缩短约 0.55 字和 0.58 字。输出长度与自回归解码开销相关，具体耗时还与生成词元数及运行状态有关。

TextRank 的三项指标略低于前 30 字截取。两种方法在 725 条测试样本中有 357 条输出完全一致，其余样本的选句与长度差异影响了总体得分。资讯摘要中的篇首信息与单句排序结果值得进一步比较。

3.3 典型案例分析

以下案例取自自划分测试集，列出完整输入与实际输出。参考摘要是数据集提供的标题式文本；表中比较前 30 字、TextRank 与 2K、10K 模型的束搜索结果。

表 3: 住宅库存案例的摘要结果

原文	截至 7 月底，35 城商品住宅累计库存余量 30216 万平，同比增 39%；存销比达 22.58 个月，同比涨 61%。业内认为，多数城市救市效果不佳，房企势必会在 9-10 月加大推盘力，适度价格策略调整，将成大多数房企的必然选择。
参考摘要	35 城市住宅库存 3 亿平米：全国性降价潮不可避免
前 30 字	截至 7 月底，35 城商品住宅累计库存余量 30216 万平，同比增
TextRank	截至 7 月底，35 城商品住宅累计库存余量 30216 万平，同比增
2K 束搜索	35 城商品住宅累计库存 30216 万平
10K 束搜索	35 城商品住宅累计库存 30216 万平同比涨 61%

前 30 字保留了库存数量，却在同比增幅处截断；2K 模型准确保留了库存量。10K 模型将原文中存销比上涨 61% 连接到库存数量，造成数值归属错误。该例说明数字本身出现在原文中，也可能在生成时与错误的指标搭配。

表 4: 规划发布案例的摘要结果

原文	“一带一路”战略已成为全国两会最为热议的话题之一，不少代表委员为“一带一路”建言献策。据内媒第一财经日报消息，“一带一路”规划已于去年底获党中央和国务院通过，有望在全国两会结束后发布。
参考摘要	一带一路规划望两会后发布战略魅力引国内外关注
前 30 字	“一带一路”战略已成为全国两会最为热议的话题之一，不少代表委
TextRank	“一带一路”战略已成为全国两会最为热议的话题之一，不少代表委
2K 束搜索	“一带一路”战略已成全国两会最热议话题
10K 束搜索	“一带一路”规划去年底获国务院通过

原文包含规划通过和预计发布两个事件。截取和 TextRank 在此例中均停留在两会讨论背景；2K 模型选择了热议话题，10K 模型选择了规划通过的信息，两者均未表达参考摘要强调的预计发布时间。输出与参考不完全一致，也反映短摘要需要在多个事实之间取舍。

表 5: 整改通报案例的摘要结果

原文	在“自曝家丑”中，一些改革信息也渐次透露出来。在一汽集团的通报中，提到了关于 2002 年未经班子集体决策违规挪用公款 2340 万在净月开发区购买土地建 131 栋别墅没追责及“大庭院别墅”庭院面积整改不彻底的问题。
参考摘要	一汽整改报告自曝家丑：挪用公款建别墅未被追责
前 30 字	在“自曝家丑”中，一些改革信息也渐次透露出来。在一汽集团的通
TextRank	在“自曝家丑”中，一些改革信息也渐次透露出来。
2K 束搜索	“大庭院别墅”庭院面积整改不彻底
10K 束搜索	一汽集团违规挪用 2340 万建 131 栋别墅

截取基线保留背景而未给出具体违规事项；2K 模型选择庭院整改问题，10K 模型保留挪用金额和别墅数量，与参考摘要所述事项更接近。原文还提到未追责，两个模型均未完整覆盖这一信息。

4 分析与讨论

4.1 模型效果与错误类型

不同训练规模的比较显示，增加训练数据改善了本实验的平均指标；案例分析进一步展示了摘要中的事实关联问题。住宅库存案例中，10K 输出包含了原文中的两个数字，却把不同统计量连接起来；识别这类错误需要核对数字与指标、主体之间的关系。整改通报案例表明，模型也会遗漏参考摘要中的追责信息。对资讯预览而言，保留谁做了什么、发生在何时以及关键数量分别对应什么，是评价摘要是否可用的必要步骤。

模型输出明显短于抽取结果，这有助于快速浏览，同时也压缩了交代背景和限定条件的空间。参考摘要本身具有编辑选择，可能强调原文中某个判断，而模型偏向具体事件或数字；因此 ROUGE 较低既可能来自信息遗漏，也可能来自对同一文本选择了不同重点。上述案例展示了模型在信息选择和事实关联方面的表现。

4.2 实验局限与改进方向

本文从有标签验证数据中划分测试集并用于比较方法；后续可使用独立测试集评价最终选定的方案。每种设置使用一个随机种子训练一次；多次重复实验可进一步检验指标差异的稳定性。各数据划分之间已排除原文精确重复，后续可进一步检查报道同一事件的近似文本。

进一步研究可增加不同随机种子的重复实验，检查长文本截断比例，并在独立测试集上报告均值与波动。对事实一致性，可抽样标注实体、数量及其对应关系，并比较不同解码策略下的错误类型。若采用更大训练集，也应保持验证和测试划分不变，以区分训练规模与测试样本变化的影响。

5 总结

本文面向中文资讯摘要，使用预训练 BART 进行全参数微调，比较训练规模、解码策略与两种抽取基线。在 725 条自划分测试样本上，10K 束搜索取得 0.3480、0.2229 和 0.3140 的 ROUGE-1、ROUGE-2 和 ROUGE-L，优于本次比较的其余方法。训练日志显示两组模型后期均出现验证损失回升，验证集选模有助于避免使用后期检查点。案例分析发现模型能够提取事件信息，但仍存在信息遗漏和数字归属错误，后续需要结合独立测试与人工事实性评价进一步检验。

参考文献

[1] Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need[C]//Advances in Neural Information Processing Systems 30. 2017: 5998–6008.

[2] Lewis M, Liu Y, Goyal N, et al. BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension[C]//ACL. 2020: 7871–7880. https://aclanthology.org/2020.acl-main.703/.

[3] Hu B, Chen Q, Zhu F. LCSTS: A Large Scale Chinese Short Text Summarization Dataset[C]//EMNLP. 2015: 1967–1972. https://aclanthology.org/D15-1229/.

[4] aligeniewcp22. LCSTS 数据集说明 [EB/OL]. https://huggingface.co/datasets/aligeniewcp22/LCSTS/blob/main/README-ZH.md.

[5] OpenMOSS-Team. Chinese BART-Base 模型说明 [EB/OL]. https://huggingface.co/OpenMOSS-Team/bart-base-chinese.

[6] Mihalcea R, Tarau P. TextRank: Bringing Order into Text[C]//Proceedings of EMNLP. 2004: 404–411. https://aclanthology.org/W04-3252/.

[7] Lin C Y. ROUGE: A Package for Automatic Evaluation of Summaries[C]//Text Summarization Branches Out. 2004: 74–81. https://aclanthology.org/W04-1013/.